

Leitfaden zur Erarbeitung der KI-Risiken für das KI-Cockpit

Zielgruppen

Die Zielgruppen dieser Übung sind Mitarbeitende der jeweiligen Anwendungsbereiche (z. B. Personalwesen, Pflege, Verkehrssteuerung), in denen das KI-System eingesetzt werden soll. Bei der Besetzung der Kleingruppen sollte idealerweise eine Diversität in folgenden Dimensionen gegeben sein:

- Funktion im Unternehmen
(z.B. Betriebsrat, Diversity-, Gleichstellungs-, Behinderten- und Datenschutzbeauftragte, Personalabteilung usw.)
- Vielfalts- und potentiellen Diskriminierungskriterien
(z.B. Alter, Geschlecht / geschlechtliche Identität und ethnische Herkunft / Nationalität)

Die feldspezifischen Expertisen der Teilnehmenden sollen zu einer umfassenden „Risikolandkarte“ beitragen. Als Expert:innen des jeweiligen Anwendungskontextes besitzen sie spezifisches Wissen über die Abläufe, die Strukturen und Akteure. Die technische Expertise vervollständigt das „Risikomapping“ mit den Informationen zur KI-Anwendung.

Ziele und Vorgehen

In der gemeinsamen Erarbeitung soll eine erste Auseinandersetzung mit den Risiken des jeweiligen Kontextes der KI-Anwendung ermöglicht werden. Dabei sollen die Felder KI-Anwendung, Akteure, Kontext, Ressourcen und Ziele, und dazu entsprechende Leitfragen die Teilnehmenden unterstützen die Risikolandkarte auszufüllen, relevante Risiken zu identifizieren und zu priorisieren. Dieses **partizipative Risikoanalyse** hat das Ziel für das Anwendungsfeld relevante Risiken und entsprechende Maßnahmen zu benennen. Auf dieser Grundlage sollen dann Expert:innen im Rahmen des **Risikomanagements** die Risiken konkretisieren und im weiteren Schritt diese in das KI-Cockpit implementieren.

1. Partizipatives Risikoanalyse
 - 1.1 Identifikation der Risiken und ihre Priorisierung
 - 1.2 Spezifikation der Risiken und ihrer Maßnahmen
2. Risikomanagement
 - 2.1 Konkretisierung und Implementierung der Risiken und ihrer Maßnahmen

Ablauf

1. **Vorbereitung:** Vorab werden die Informationen zur KI-Anwendung eingetragen (z.B. durch IT-Abteilung)
2. **Arbeitsphase 1:** Die Arbeit auf dem Plakat beginnt. Die drei Schritte 1. Kontext 2. Risiken 3. Priorisierung werden durchlaufen. Die auf dem Plakat veranschlagten Zeiten sind grobe Richtlinien für ein eher einfaches System. Passen Sie diese ggf. an. (Veranschlagte Arbeitszeit auf Plakat: 120 Minuten).
3. **Arbeitsphase 2:** Spezifizieren sie die Risiken & Maßnahmen vom höchstpriorisierten abwärts mithilfe des Arbeitsblattes. (~60 Minuten)
4. **Ergebnis:** Priorisierte und beschriebene Risiken des KI-Systems in ihrem Verwendungskontext, sowie Maßnahmenvorschläge zur Minimierung des Risikos. Die Risiken und Maßnahmen können in dieser Form einen Beitrag zu ihrem allgemeinen Software-Risikomanagement darstellen, sowie die Grundlage für die Wahl und Konfiguration des KI-Cockpits bilden. Für die Durchführung des konkreten Risikomanagements, durch die Implementierung von menschlicher Aufsicht mit einem KI-Cockpit, lesen Sie gerne das KIC-Vorgehensmodell: <https://www.kicockpit.eu/>

Relevante Begriffe

Risiko: Wahrscheinlichkeit eines Schadenseintritts durch fehlerhaftes oder schädliches Verhalten einer KI-Anwendung: negative Auswirkungen auf Nutzer:innen, Betroffene oder die (unmittelbare) Umgebung, dabei sowohl potenzielle materielle als auch immaterielle Schäden, Risiken für Organisationen bzw. die Personen verbunden, welche die Verantwortung für die KI-Anwendung tragen.

Risikoanalyse: Ziel der Risikoanalyse ist es festzustellen, welche der potenziellen Risiken des Risikogebiets für die spezifische KI-Anwendung relevant sind und beherrscht werden müssen.

Maßnahmen: konkrete technische und organisatorische Maßnahmen, die relevante Risiken auf ein akzeptables Maß mindern oder die Beherrschung dieser Risiken durch Tests nachweisen.

<u>Schlagworte zur Anregung</u>	
Fairness und Diskriminierung ggf. relevant für: - KI-Anwendung - Akteure - Kontext - Ressourcen - Ziele	Autonomiegrade, Nutzendenautonomie und menschliche Aufsicht ggf. relevant für: - KI-Anwendung - Akteure - Kontext - Ziele
Informiertheit und Vertrauen ggf. relevant für: - Akteure - Kontext - Ziele	Transparenz und Nachvollziehbarkeit ggf. relevant für: - KI-Anwendung - Akteure